

La Recherche Reproductible en Science Computationnelle

Contexte : montée en puissance du calcul scientifique

L'essor des grandes bases de données publiques (ex : Sloan Digital Sky Survey) permet à des chercheurs de faire des découvertes **sans collecter leurs propres données**. Cette révolution expose une limite majeure : notre capacité à évaluer et vérifier les résultats publiés.

Réplication vs Reproductibilité

Distinction fondamentale

Réplication (gold standard) : des chercheurs indépendants collectent de nouvelles données et testent la même hypothèse. Reproductibilité (standard minimal) : les mêmes données et le même code sont rendus disponibles pour que d'autres puissent vérifier l'analyse. La reproductibilité ne remplace pas la réplication, mais comble le vide entre "publication seule" et "réplication complète".

Le spectre de la reproductibilité

Peng propose un continuum allant de "non reproductible" à "réplication complète" (gold standard) :

- Publication seule : aucun code ni données disponibles.
- Publication + code : le code est fourni, sans les données.
- Code et données : les deux sont disponibles pour re-analyse.
- Code et données liés et exécutables : la reproductibilité est maximale, proche du gold standard.

Les obstacles à la reproductibilité

- Le code n'est souvent plus disponible après publication (logiciels interactifs sans trace écrite).
- Les chercheurs utilisent plusieurs packages et ne sauvegardent pas le code qui les relie.
- Les habitudes sont difficiles à changer ; les logiciels propriétaires bloquent les modifications.
- Absence d'une culture et d'une infrastructure intégrée pour partager code et données.

L'initiative de la revue Biostatistics

La revue *Biostatistics* a mis en place une politique de reproductibilité (juillet 2009) :

- Les auteurs peuvent soumettre code et/ou données comme matériel supplémentaire.
- Les articles reçoivent un kite-mark "D" (données), "C" (code) ou "R" (reproductible, après vérification par un éditeur).
- En 2 ans, 21 articles sur 125 ont reçu un kite-mark, dont 5 un "R".

Recommandations concrètes (ordre croissant d'impact)

- Publier son code immédiatement, même imparfait, sur GitHub ou en matériel supplémentaire.
- Publier une version propre du code avec les données dans un format ouvert et durable.
- Créer un DataMed Central et CodeMed Central (analogue à PubMed Central) comme dépôt universel de code, données et métadonnées.

Conclusion

La reproductibilité ne garantit pas la qualité d'un résultat, mais permet de **traquer les erreurs** et de **bâtir sur les découvertes**. Développer une culture de la reproductibilité exige du temps et un effort collectif soutenu.