

Invitation à la Recherche Computationnelle Reproductible

Contexte et motivation personnelle

Donoho a été inspiré par John Claerbout (Stanford) il y a plus de 15 ans. La citation fondatrice : *"Un article sur un résultat computationnel n'est que de la publicité, pas de la science. La véritable science, c'est l'environnement logiciel complet — code et données — qui a produit le résultat."*

L'auteur observe que l'erreur est **omniprésente** en calcul scientifique et que les chercheurs oublient souvent ce qu'ils ont fait, voire le décrivent de façon inexacte.

Pourquoi travailler de façon reproductible ?

En tant que scientifique

- Amélioration du travail et des habitudes : travailler vers un ensemble de scripts publiables force la transparence et la qualité.
- Meilleur travail en équipe : les collaborateurs voient exactement ce qui a été fait et peuvent proposer des améliorations ciblées.
- Plus grand impact : les méthodes publiées sont plus facilement réutilisées, ce qui augmente les citations et réduit la concurrence involontaire.
- Continuité et impact cumulatif : former de nouveaux étudiants est plus efficace si les projets passés sont reproductibles ; ils peuvent s'en emparer et les adapter.

En tant que citoyen / contribuable

- Stewardship des fonds publics : les résultats computationnels financés publiquement ne doivent pas être "perdus" à la fin du projet. Sous le standard de reproductibilité, cela ne se produit pas.
- Accès public aux biens publics : la publication dans une revue ne suffit pas à transmettre la "connaissance" computationnelle en profondeur. Le code et les données sont indispensables.

Comment travailler de façon reproductible ?

La reproductibilité ne s'ajoute pas à la fin : elle doit être **planifiée dès le début du projet**.

- Concevoir le projet autour d'un script unique (ex : R) qui génère toutes les figures et tables de l'article.
- Éviter l'approche "interactive" (commandes tapées au clavier sans trace) qui n'est jamais reproductible.
- Adopter des disciplines de programmation claires dès le départ et s'y tenir.

Initiatives et ressources existantes

- Biostatistics (2009) : kite-marks D/C/R pour récompenser les auteurs qui partagent données et code.

- IEEE Computing in Science & Engineering (2009) : numéro spécial sur la reproductibilité (géosciences, traitement du signal).
- Groupe de Vetterli (EPFL) : dépôt de recherche reproductible avec avis d'utilisateurs sur la reproductibilité effective des papiers.
- GenePattern (Mesirov, 2009) : système dédié à la biologie computationnelle avec interface grand public.
- Licences de reproductibilité (Stodden, 2009) : cadre légal pour citer les travaux reproductibles réutilisés.

Bénéfices observés sur 15+ ans

L'auteur témoigne de dividendes multiples après 15 ans de pratique reproductible dans son groupe :

- Des utilisateurs parviennent encore aujourd'hui à reproduire des résultats publiés il y a 18 ans.
- L'impact en citations est significativement supérieur pour les travaux reproductibles.
- L'intégration de nouveaux étudiants est facilitée : prendre un projet passé et l'adapter est un excellent exercice d'apprentissage.

Conclusion

Donoho espère qu'une **masse critique** de chercheurs adoptera la reproductibilité computationnelle comme composante essentielle de la publication scientifique. Cela améliorera à la fois la fiabilité et l'impact de la littérature publiée.